

Deep Learning

4A – IABD - ESGI

Me contacter

- pro@nicolasvidal.fr
- Discord: NicolasVidal#2440

Plan du cours

Machine Learning Rappels	Classification / Régression, Supervisé / non Supervisé, good practices Retours et rappels sur les modèles vus l'année précédente Installation et configuration de l'environnement de développement Keras Ré implémentation des modèles vus l'année précédente avec Keras
ConvNets	Traitement d'images et noyaux de convolution Apprentissage du noyau de convolution ConvNets Application à Cifar-10
Regularisation	Evaluation intermédiaire : Présentation des premiers résultats obtenus sur les compétitions Evaluation intermédiaire : QCM Régularisation classique : L2 Présentation Dataset évaluation finale
Méthodes modernes	Régularisation avancée : Dropout Fonctions d'activation modernes : ReLU, LeakyRelu,... X-Fold CrossValidation Coaching projet Transformers
Recurrent neural networks	introduction aux RNN et LSTMs utilisation des LSTMs pour générer du texte Soutenance Projet

De manière un peu plus détaillée...

- Cf Syllabus

Que vous reste-t-il de l'année dernière ?

Supervisé vs Non supervisé

- Supervisé :
 - « J'ai des informations détaillées sur la forme physique de 20 000 utilisateurs, et je sais si ces derniers ont acheté ou non mon produit quand il le leur a été présenté, puis-je construire un modèle permettant de prédire l'acceptation ou le refus de l'achat pour un nouvel utilisateur ? »
- Non supervisé :
 - « J'ai des informations détaillées sur la forme physique de 20 000 utilisateurs, existe-t-il des types d'utilisateurs bien distincts ? »

Classification vs Régression

- Classification :
 - « Fera-t-il fera beau demain ? »
- Régression :
 - « Quelle température fera-t-il demain ? »

Classification vs Régression

- Classification :
 - « Ce visiteur est-il un acheteur potentiel ? »
- Régression :
 - « Combien ce visiteur peut-il dépenser dans mon magasin ? »

Classification vs Régression

- Classification (multi-classes) :
 - « A quelle catégorie socio professionnelle appartient ce patient ? »
- Régression :
 - « Jusqu'à quel montant ce patient peut-il rembourser ses soins ? »

Installation et configuration de Keras

Softmax et Categorical Cross Entropy

SGD

Règle de mise à jour des variables du modèle :

$$w_{t+1} = w_t - \alpha \frac{\partial loss}{\partial w_t}$$

Avec :

w_t est une variable (poids, biais, ...) du modèle à l'iteration t

w_{t+1} est la même variable mise à jour à l'iteration $t + 1$

α est le pas d'apprentissage

$\frac{\partial loss}{\partial w_t}$ est la dérivée de la fonction de loss (perte) par rapport à la variable considérée

SGD + momentum classique

Règle de mise à jour des variables du modèle :

$$v_{t+1} = \gamma v_t - \alpha \frac{\partial loss}{\partial w_t}$$
$$w_{t+1} = w_t + v_{t+1}$$

Avec :

w_t est une variable (poids, biais, ...) du modèle à l'iteration t

w_{t+1} est la même variable mise à jour à l'iteration $t + 1$

α est le pas d'apprentissage

$\frac{\partial loss}{\partial w_t}$ est la dérivée de la fonction de loss (perte) par rapport à la variable considérée

v_t est la vitesse (l'élan) de la variable à l'iteration t

v_{t+1} est la vitesse (l'élan) de la variable à l'iteration $t + 1$

γ est un facteur d'attenuation (la valeur du momentum), souvent réglé entre 0.5 et 0.99

SGD + EMA momentum

Règle de mise à jour des variables du modèle :

$$v_{t+1} = \gamma v_t + (1 - \gamma) \frac{\partial loss}{\partial w_t}$$
$$w_{t+1} = w_t - \alpha v_{t+1}$$

Avec :

w_t est une variable (poids, biais, ...) du modèle à l'iteration t

w_{t+1} est la même variable mise à jour à l'iteration $t + 1$

α est le pas d'apprentissage

$\frac{\partial loss}{\partial w_t}$ est la dérivée de la fonction de loss (perte) par rapport à la variable considérée

v_t est la moyenne mobile (roulante) exponentielle de la dérivée à la date t

v_{t+1} est la moyenne mobile (roulante) exponentielle de la dérivée à la date $t+1$

γ (on utilise aussi le symbole β de temps à autre) est un facteur d'atténuation (la valeur du momentum), souvent réglé entre 0.9 et 0.99

RMSProp

Règle de mise à jour des variables du modèle :

$$s_{t+1} = \gamma s_t + (1 - \gamma) \left(\frac{\partial loss}{\partial w_t} \right)^2$$

$$w_{t+1} = w_t - \frac{\alpha}{\sqrt{s_{t+1} + \epsilon}} \times \frac{\partial loss}{\partial w_t}$$

Avec :

w_t est une variable (poids, biais, ...) du modèle à l'iteration t

w_{t+1} est la même variable mise à jour à l'iteration $t + 1$

α est le pas d'apprentissage

$\frac{\partial loss}{\partial w_t}$ est la dérivée de la fonction de loss (perte) par rapport à la variable considérée

s_t est la moyenne mobile (roulante) exponentielle du carré de la dérivée à la date t

s_{t+1} est la moyenne mobile (roulante) exponentielle du carré de la dérivée à la date $t+1$

γ (on utilise aussi le symbole β de temps à autre) est un facteur d'atténuation (aussi appelé décomposition), souvent réglé entre 0.9 et 0.99

ϵ est une petite valeur pour éviter la division par 0

Adam (sans correction du biais de l'EMA)

Règle de mise à jour des variables du modèle :

$$v_{t+1} = \gamma_1 v_t + (1 - \gamma_1) \frac{\partial loss}{\partial w_t}$$

$$s_{t+1} = \gamma_2 s_t + (1 - \gamma_2) \left(\frac{\partial loss}{\partial w_t} \right)^2$$

$$w_{t+1} = w_t - \frac{\alpha}{\sqrt{s_{t+1} + \epsilon}} \times v_{t+1}$$

Avec :

w_t est une variable (poids, biais, ...) du modèle à l'iteration t

w_{t+1} est la même variable mise à jour à l'iteration $t + 1$

α est le pas d'apprentissage

$\frac{\partial loss}{\partial w_t}$ est la dérivée de la fonction de loss (perte) par rapport à la variable considérée

v_t est la moyenne mobile (roulante) exponentielle de la dérivée à la date t

v_{t+1} est la moyenne mobile (roulante) exponentielle de la dérivée à la date $t + 1$

s_t est la moyenne mobile (roulante) exponentielle du carré de la dérivée à la date t

s_{t+1} est la moyenne mobile (roulante) exponentielle du carré de la dérivée à la date $t + 1$

γ_1 (on utilise aussi le symbole β_1 de temps à autre) est un facteur d'atténuation (aussi appelé de décomposition), souvent réglé à 0.9

γ_2 (on utilise aussi le symbole β_2 de temps à autre) est un facteur d'atténuation (aussi appelé de décomposition), souvent réglé à 0.999

ϵ est une petite valeur pour éviter la division par 0

Adam (avec correction du biais de l'EMA)

Règle de mise à jour des variables du modèle :

$$v_{t+1} = \gamma_1 v_t + (1 - \gamma_1) \frac{\partial loss}{\partial w_t}$$

$$\hat{v}_{t+1} = \frac{v_{t+1}}{1 - \gamma_1^{t+1}}$$

$$s_{t+1} = \gamma_2 s_t + (1 - \gamma_2) \left(\frac{\partial loss}{\partial w_t} \right)^2$$

$$\hat{s}_{t+1} = \frac{s_{t+1}}{1 - \gamma_2^{t+1}}$$

$$w_{t+1} = w_t - \frac{\alpha}{\sqrt{\hat{s}_{t+1} + \epsilon}} \times \hat{v}_{t+1}$$

Avec :

w_t est une variable (poids, biais, ...) du modèle à l'iteration t

w_{t+1} est la même variable mise à jour à l'iteration $t + 1$

α est le pas d'apprentissage

$\frac{\partial loss}{\partial w_t}$ est la dérivée de la fonction de loss (perte) par rapport à la variable considérée

v_t est la moyenne mobile (roulante) exponentielle de la dérivée à la date t

v_{t+1} est la moyenne mobile (roulante) exponentielle de la dérivée à la date $t + 1$

s_t est la moyenne mobile (roulante) exponentielle du carré de la dérivée à la date t

s_{t+1} est la moyenne mobile (roulante) exponentielle du carré de la dérivée à la date $t + 1$

γ_1 (on utilise aussi le symbole β_1 de temps à autre) est un facteur d'attenuation (aussi appelé de décomposition), souvent réglé à 0.9

γ_2 (on utilise aussi le symbole β_2 de temps à autre) est un facteur d'attenuation (aussi appelé de décomposition), souvent réglé à 0.999

ϵ est une petite valeur pour éviter la division par 0